



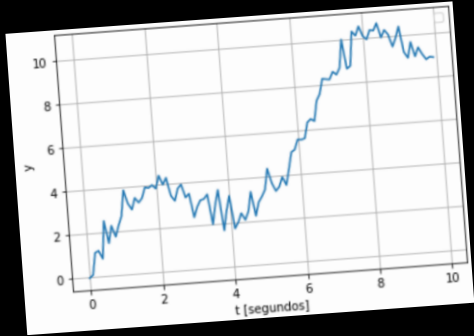
# Clasificación Binaria

*Definición y ejemplos*




*DeepData*

# Clasificación Binaria – Introducción



	Columna_1	Columna_2	Columna_3	Columna_4	Columna_5
0	68	5	75	34	28
1	92	94	35	96	54
2	11	69	17	42	35
3	63	95	12	77	50
4	76	92	78	84	84
5	52	8	3	16	65
6	10	58	51	42	53
7	44	25	96	18	32
8	19	81	90	92	42
9	83	90	52	65	90






Clase 1

Clase 2



# *Clasificación Binaria – Introducción*





**Gato**



**Perro**


# *Clasificación Binaria – Introducción*



**Gato – 90 %**

**Perro – 10 %**

# Clasificación Binaria – Ejemplos de aplicación



**Benigno**



**Maligno**



# Clasificación Binaria – Ejemplos de aplicación



Sano



Esquizofrénico

## Using Electroencephalographic Signal Processing and Machine Learning Binary Classification to diagnose Schizophrenia

Krish Desai

Leland High School, San Jose, United States

Corresponding author: Krish Desai (krishdesaiedu@gmail.com) ORCID ID: 0000-0003-2559-8910

**Abstract**—Electroencephalography (EEG) is an electrical activity measurement technique used to identify brain activity in schizophrenic patients. Novel machine learning methods have emerged with useful applications for Schizophrenia classification. This research aims to compare the performance of several models including, such as Random Forest (RF), Support Vector Machines (SVM), and K-Nearest Neighbors (KNN) for Schizophrenia diagnosis.

quantifying cortical brain activity [4]. Typical EEG recordings are comprised of several electrodes placed around the scalp, each measuring the electrical activity of their respective region. Machine learning methods applied to time and frequency series analysis of EEG signals show promise for an accurate and efficient SZ diagnostic intervention [5][6].

### II. BACKGROUND LITERATURE

classified under brain dysmorphology and chemical abnormalities.





# Clasificación Binaria – Definición

**Objetivo:** Tomar una entrada  $\mathbf{x}$  y asignarle una de las dos posibles clases  $C_1$ , o  $C_2$ .


Dos regiones de decisión, separadas por una frontera de decisión.

$y \in \{0, 1\}$ :

$y = 1 \rightarrow$  clase  $C_1$

$y = 0 \rightarrow$  clase  $C_2$ .

Puede interpretarse a  $y$  como la probabilidad de que la clase de  $\mathbf{x}$  sea  $C_1$ , donde los valores de probabilidad toman valores extremos de 0 y 1.





# *Clasificación Binaria – Ejemplo - práctica*



- Ejemplo básico de introducción.
- Se utiliza el dataset *breast cancer* de *scikit-learn*.
- Emplearemos *Naive Bayes*.
- Vamos a Python!



# *Clasificación Binaria – Conclusiones y continuación*



- Logramos introducir la idea general de un clasificador binario.
- Existe una amplia variedad de modelos útiles para distintos tipos de aplicaciones.
- Índices de desempeño o métricas son necesarios para comparar distintas alternativas.

